# 基于 BM25 与向量检索的中文搜索引擎

## 自适应混合检索 · 开题报告

石皓文 · 张恩瑞 · 许程 · 杜鹏宇

2026-10-22

# 报告提纲

1 词法检索与语义检索

2 评测指标与公开基线

3 方案与实验

# 搜索引擎做了什么

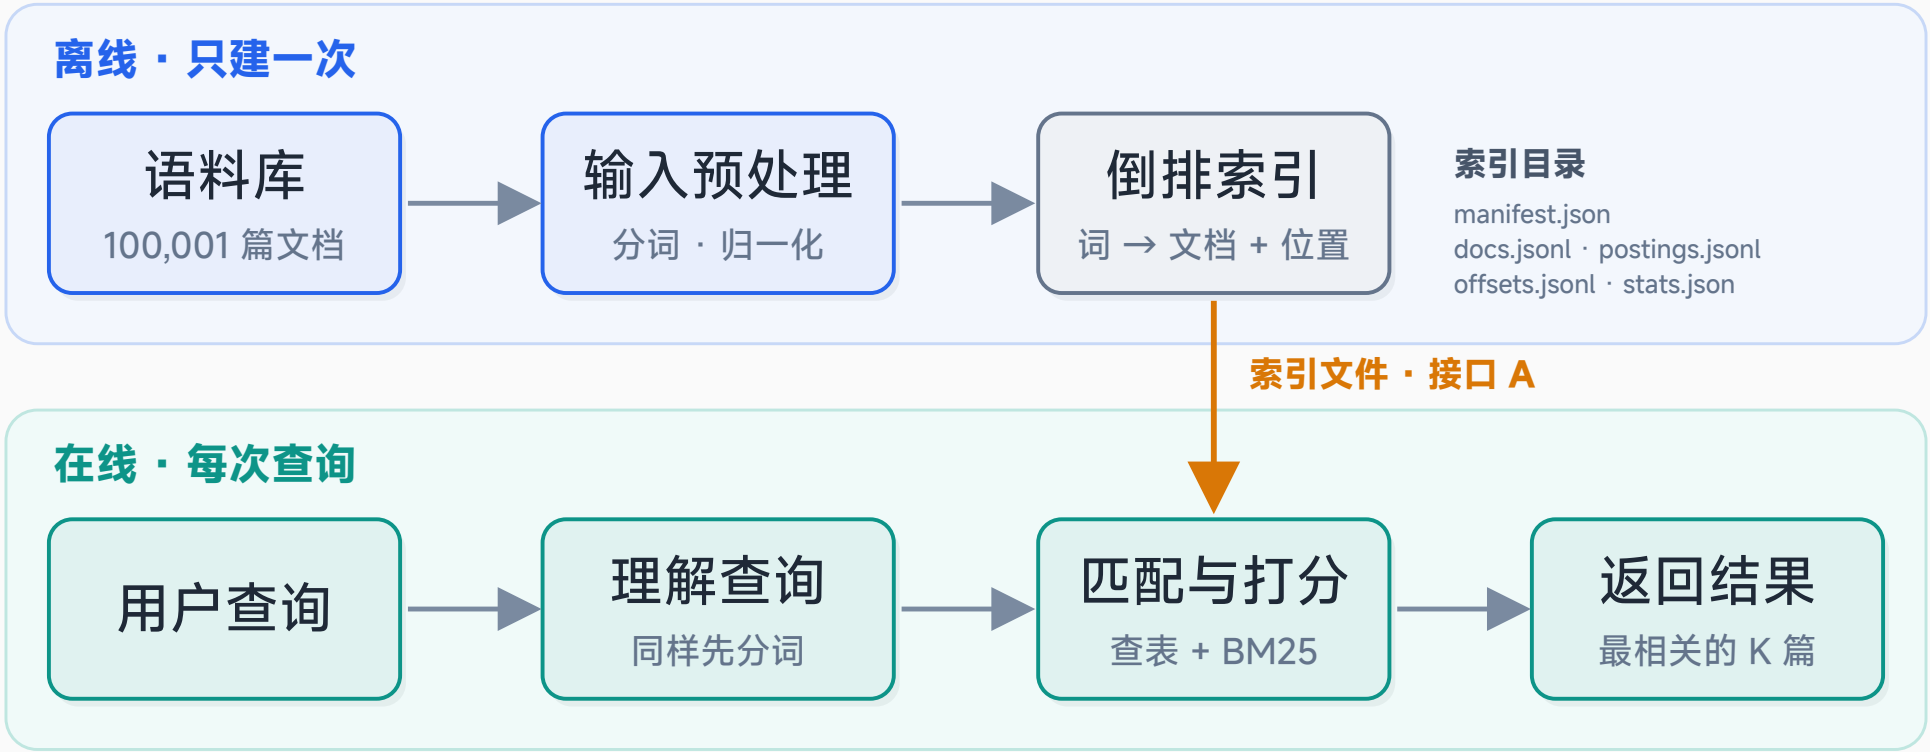
# 一次查询的规模

语料 **100,001 篇** 文档，

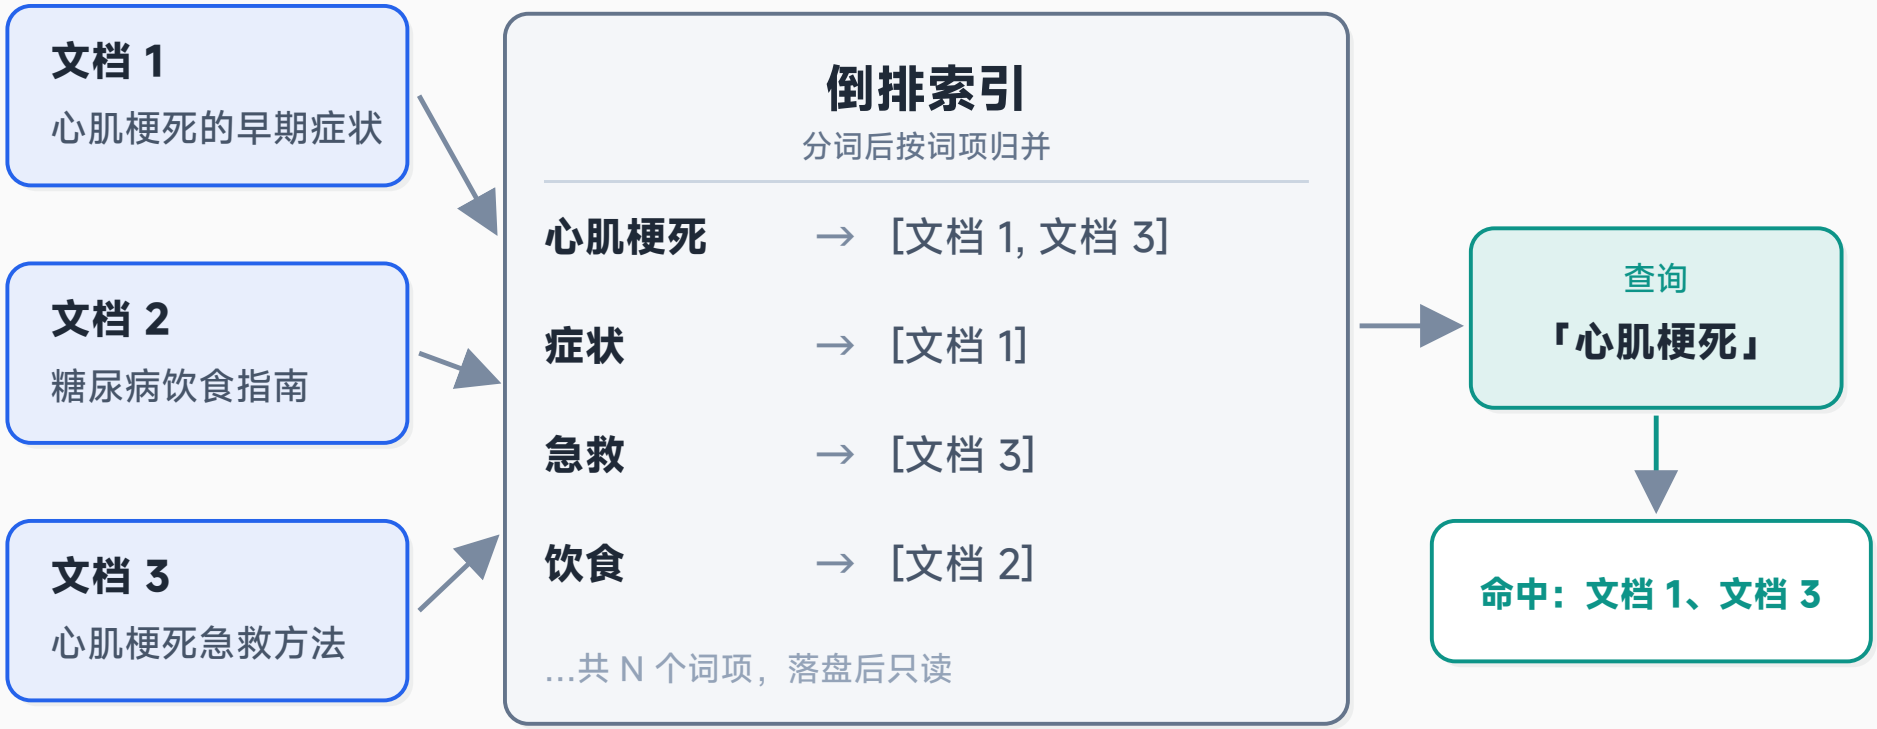
BM25 单查目标 **p95 < 100 ms**，

结果按相关度 **取前 10 篇**。

# 词法检索：离线建索引，在线查索引



# 核心数据结构是倒排索引




每个词项挂一张文档表；查询在命中词项的倒排表上直接打分

# BM25：按词项匹配程度给文档打分

**输入：查询词 + 倒排表中的词频与文档长度**

**IDF**：越罕见的词，区分文档的能力越强。

**词频饱和**：重复加分，边际收益递减。

**长度归一化**：抵消长文档靠词数堆出来的优势。

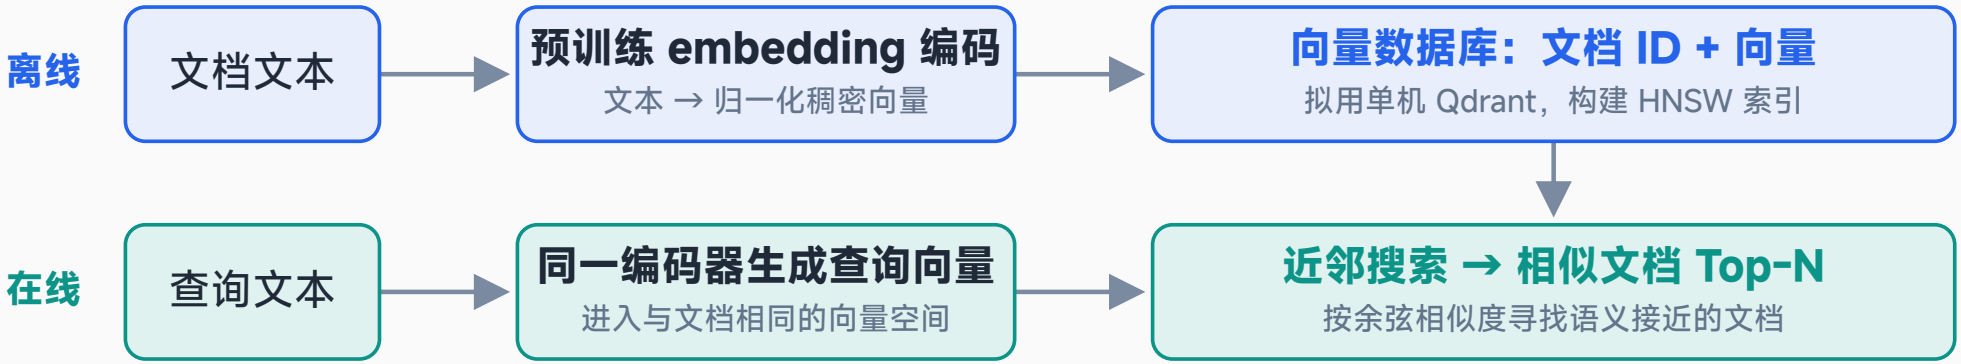
**词面零重合，BM25 就命中不了**

查询：手机掉水里怎么办
文档：设备进液后的应急措施

查询与文档同义，共享词项却为零。型号、术语、专名恰好是它的强项。

只访问命中词项的倒排表；核心打分与索引由我们自行实现

# 向量数据库：编码文本，再搜索相似向量




## 相似度：归一化向量的点积

$$\mathrm{sim}(q, d) = \frac{q \cdot d}{\|q\| \|d\|}$$

语义相近即得高分，词面可以完全不同。

## HNSW：分层近邻图上的近似搜索

上层快速导航到邻近区域，下层扩大局部搜索；候选范围越大，召回越高，耗时同步上升。

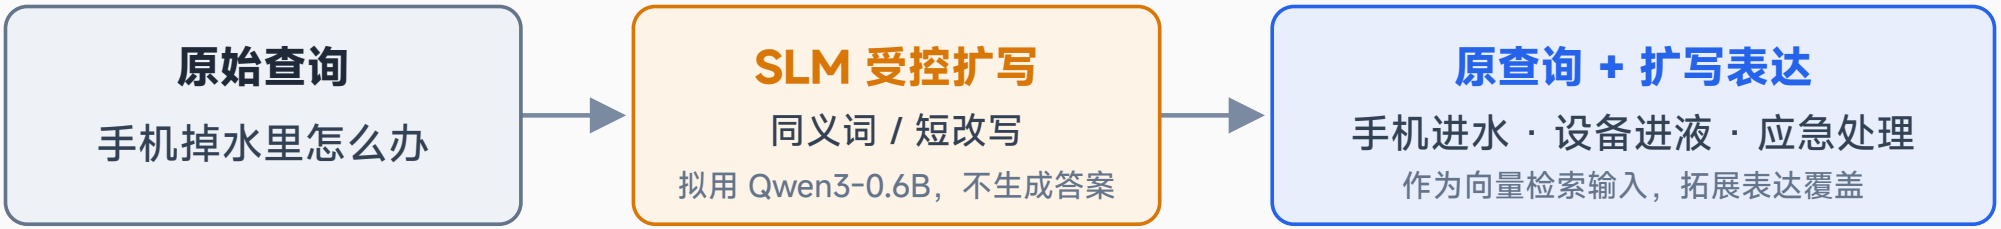
复用预训练中文编码器，检索层交付排序结果，答案生成留给上层应用；HNSW 为近似搜索，额外核对 Top-N 召回率

# BM25 与向量检索：优势互补，成本不同

| 比较维度 | BM25 · 词法检索 | 向量检索 · 语义匹配 |
| --- | --- | --- |
| 匹配依据 | 词频、IDF、文档长度 | 编码器表示、向量相似度 |
| 典型优势 | 精确术语、型号、关键词 | 同义表达、自然语言描述 |
| 主要风险 | 词面不重合时可能漏检 | 语义接近但事实或型号不符 |
| 离线成本 | 构建倒排表与位置索引 | 文档编码、向量存储、建近邻图 |
| 在线成本 | 分词、查表、打分 | 查询编码、近邻搜索、结果返回 |

两条路线各有失效场景，取舍落在同一语料、同一 qrels 上的实测数字

# SLM 查询扩写：为检索补充表达，不生成答案




### 做什么

用预训练小模型生成少量同义词或短改写；原查询保留，再组成第二阶段的检索输入。

### 与向量检索的区别

向量检索改变匹配空间；SLM 改变查询表达。二者可以串联，也可以跳过扩写直接检索。

### 质量与成本约束

保留实体和否定，显式约束不改写；限制生成长度，超时回退原查询，扩写收益需实测。

SLM 是可选查询预处理，不是新的排序器；生成可能引入语义漂移，需同时测量质量与耗时

# 三种查询能力

### 布尔检索

感冒 AND 发烧
NOT 流感

### 短语检索

“心肌梗死的症状”
按连续位置匹配

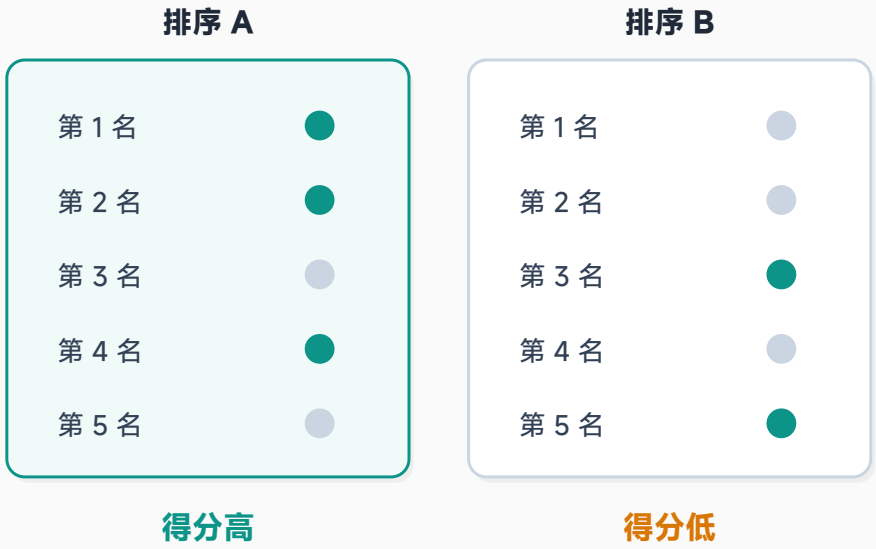
### 语义检索 ★ 混合检索

手机掉水里怎么办
⇒ 设备进液后的应急措施

自然语言查询默认先走 BM25，再按路由信号补语义
显式 AND / NOT / 引号作为硬约束，在词法层过滤完再进入后续阶段

# 我们用公开数据评测检索效果

# 三个指标分别衡量排序、召回和速度




两种排序命中同样 3 篇相关文档（●）；越靠前，DCG 越高

## nDCG@10

$\mathrm{DCG} = \sum_{i=1}^{10} \mathrm{rel}_i / \log_2(i+1)$，再除以理想排序的 DCG@10

rel 取 0/1，衡量前 10 条的排序质量

## Recall@10

前 10 条覆盖的相关文档数 / 相关文档总数

衡量召回，是否漏掉相关文档

## 延迟 p95

95% 的查询快于此值；另报 p50 与索引加载耗时

衡量线上响应速度

# 所有数字都出自 DuRetrieval

| 100,001 | 2,000 | 9,839 |
| --- | --- | --- |
| 网页段落 | 查询 | 人工相关性标注 |

数据集：**DuRetrieval**，取自 C-MTEB 中文检索基准

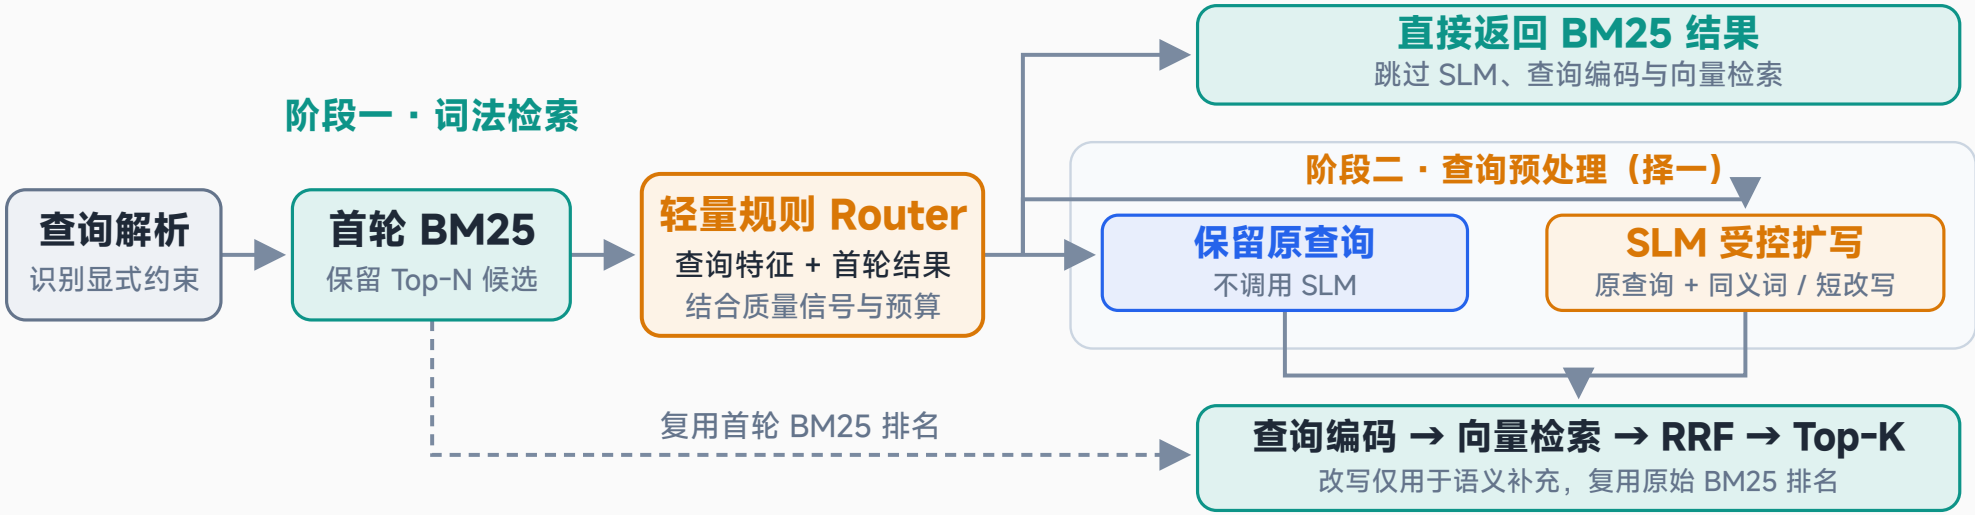
基线核对：分词、qrels 与 k1/b 统一，自实现 BM25 对 **bm25s** 基线，nDCG@10 差距 < 2%

数据统计：平均文档 331.32 字符、平均查询 9.29 字符、每查询 4.92 篇相关文档

# 方案与实验设计

# 自适应混合检索：按需语义补充，可选 SLM 扩写

**研究问题**：能否按需调用向量检索与 SLM 扩写，取得更好的质量–成本折中？




**三条路径**：直接 BM25 / 原查询向量补充 / SLM 扩写后向量补充

**保守边界**：显式约束走词法；SLM 超时退回原查询；原始 BM25 排名始终保留

查询与首轮结果特征结合调用预算；阈值在开发集冻结；SLM 仅做检索预处理，不替代轻量 Router

# RRF：按名次融合两路结果

**RRF · 倒数排名融合**

$$\mathrm{RRF}(d) = \sum_{s \in \{B,V\}} \frac{1}{c + \mathrm{rank}_{s(d)}}$$

B / V 分别是 BM25 / 向量排名；未入某路候选贡献为 0，c 在开发集固定。
按内部 docid 合并、去重、排序，同分按 docid 升序。

**RRF 只看名次**

BM25 与余弦相似度的量纲、分布随语料漂移；名次是两路共通的尺度，RRF 直接在其上融合。

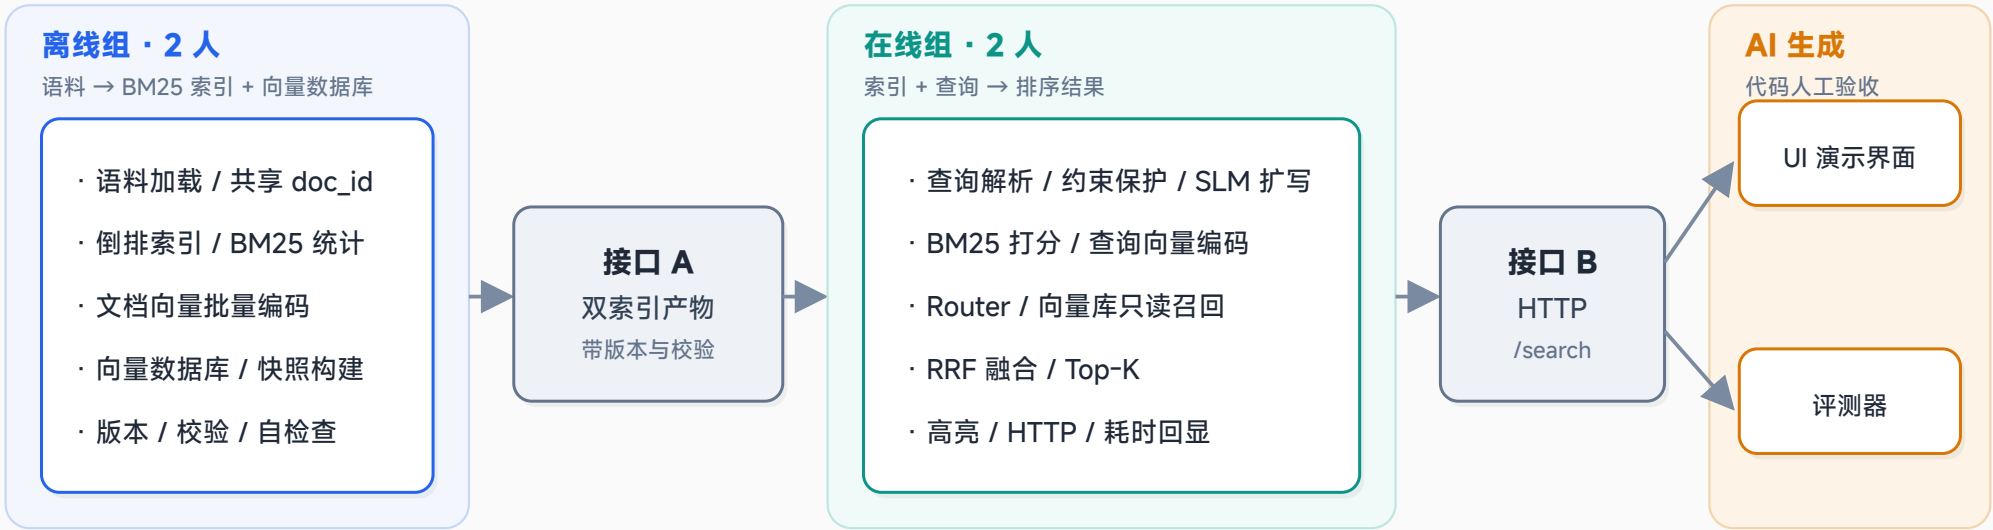
**路由省下的开销**

直接返回时跳过 SLM、查询编码、近邻搜索与融合；进入语义分支也可跳过 SLM，离线成本照常。

**自建与复用**

词法核心手写，复用预训练编码器、SLM 与向量库；SLM 只改写语义分支输入，不替换首轮候选。

# 两个接口划出两组的分工




接口 A 扩展为索引产物与版本约定：倒排索引 + 向量库快照，共用 doc_id。
接口 B 仍为 HTTP；评测器独立调用；**UI 与评测器由 AI 生成、人工验收**

# 双索引与 Router 契约已落为代码骨架

```
contracts/ 双方共有
  analyzer.py 唯一分词器+哈希
  index_format.py 接口 A·格式校验
  reader.py IndexReader 协议
  retrieval.py 向量/编码/路由配置
  api.py 接口 B·四模式+Schema
  conformance.py 同一套验收测试
offline/ 离线组
  build · build_hybrid · vector_build
online/ 在线组
  memory_index · parser · scorers · highlight
  router · fusion · vector_index · engine · server
fixtures/ tests/ 34 项契约测试通过
```

**HTTP 四种 mode 已固定**

lexical / dense / hybrid / adaptive；响应回显 routing 与 timings_ms

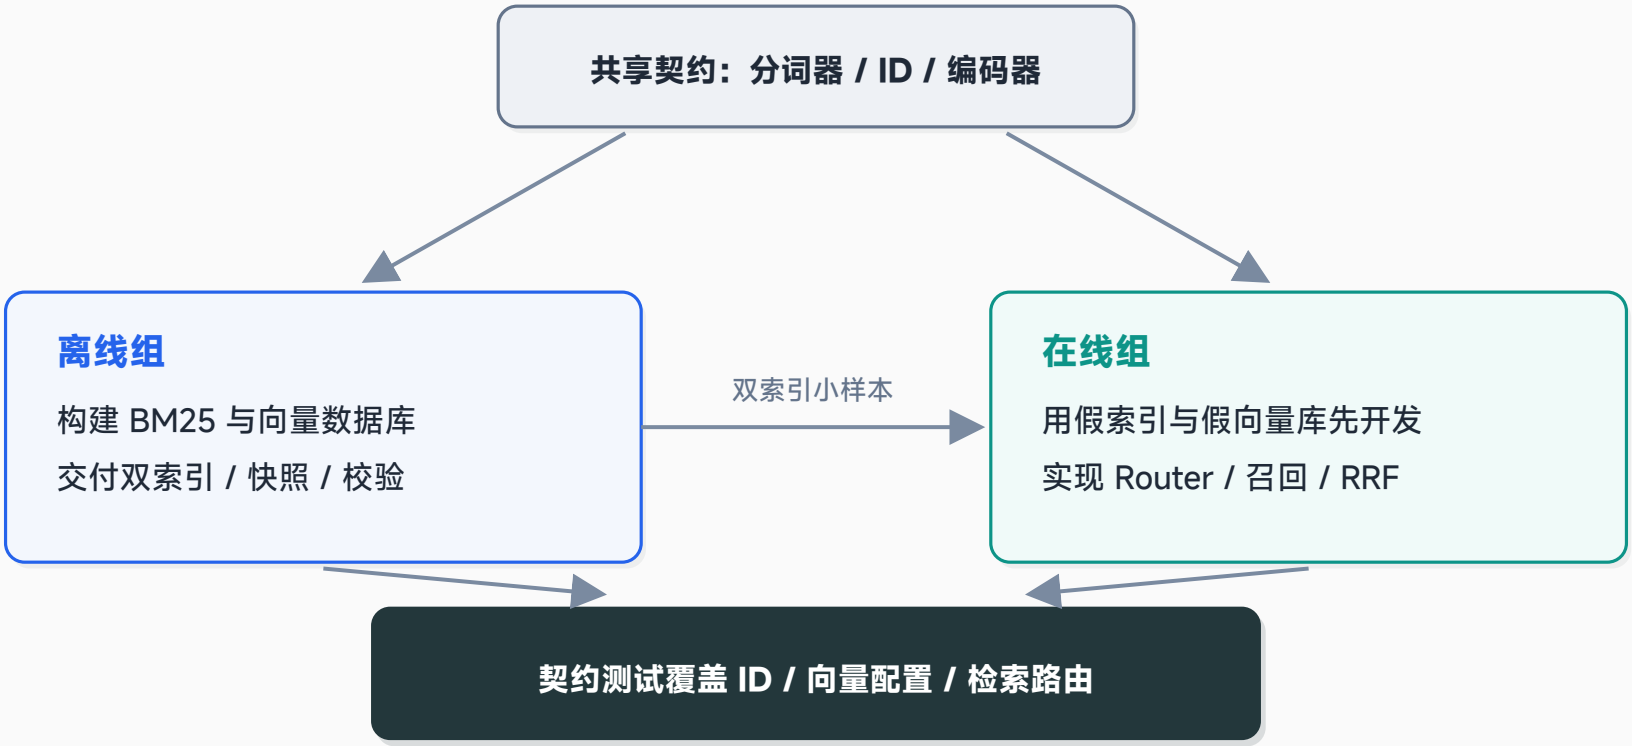
**tiny 索引已跑通**

build → load → /search 全链路跑通，双路假数据对齐

**新增：双索引一致性与 Router 测试**

校验语料指纹、ID、编码器与向量维度；真实模型 / Qdrant 与 SLM 扩写待接入

# 并行开发先冻结词法与向量两套契约




共享 doc_id 与语料版本，向量索引仅使用同一批文档；冻结编码器版本、维度与截断规则

联调单列 BM25、SLM 扩写、查询编码、向量检索与融合耗时；SLM 缓存命中 / 未命中分别计时

# 四组主实验 + SLM 查询扩写消融

| 检索方式 | nDCG@10 | Recall@10 | 延迟 | 定位 |
|---|---|---|---|---|
| BM25 | 待测 | 待测 | 待测 | 词法基线 |
| 纯向量检索 | 待测 | 待测 | 待测 | 语义基线 |
| 固定混合 + RRF | 待测 | 待测 | 待测 | 每次走两路 |
| 自适应混合 + RRF | 待测 | 待测 | 待测 | 按需走向量 ★ |
| 自适应 + SLM 扩写 | 待测 | 待测 | 待测 | 预处理增益 |

前四行分离检索 / 路由收益；末行固定同一路由、候选数与 RRF 参数，仅开关 SLM 预处理
同一语料、查询划分与 qrels；生成配置冻结，报告质量差值与 paired bootstrap 置信区间

# 路由评测：检索质量与在线成本一起看

### 1 · 开发集定规则

开发集比较 BM25 与固定混合；确定路由特征和阈值后冻结，测试集只做验证。

### 2 · 测试集看质量

冻结规则后在独立测试集比较 nDCG@10、Recall@10，报告相对固定混合的质量变化。

### 3 · 实测成本变化

记录平均延迟、p50/p95、向量与 SLM 触发率；SLM 耗时单列，区分缓存命中与未命中。

改变路由阈值，展示 **检索质量–分支触发率–平均延迟** 的权衡曲线

向量与 SLM 慢分支可能主导 p95；计入扩写开销，不把缓存加速误当算法收益

# 里程碑按依赖顺序推进




顺序约束：**带词位置的倒排索引在 E1 前定稿**

在线组的短语过滤与高亮按定稿格式开发，E1 之后双方各自推进

E2：词法 / 向量 / 固定混合基线冻结 → E3：自适应路由、SLM 消融与演示

谢谢

请各位老师批评指正